단국대학교 SW중심대학

전공별 AI활용

판다스 입문

정 복 문

Bokmoon.jung@dankook.ac.kr

CONTENTS

인공지능(AI)시대에 요구되는 능력

- 인공지능은 이미 SW 산업에서 대단한 가치를 창출하며, 미래에는 SW 산업 외에도 교통, 여행, 자동차, 제조업, 도소매 등에서 많은 가치를 창출할 것으로 전망

  -> AI 활용에 대한 관심 지속적으로 증가

- 글로벌 컨설팅 기업 맥킨지(Mckinsey)가 발표한 'AI가 세계 경제에 미치는 영향'이라는 보고서에 따르면, 인공지능에 대한 투자가 없는 기업은 2030년 현금 창출이 23%나 하락할 것으로 예상했음

- 미국의 MIT는 모든 학생을 인공지능 전문가로 양성하겠다고 선언한 바 있음. 이는 비IT 학생들에게도 인공지능에 대하여 의무적으로 배우도록 함으로 자신의 전공 분야와 융합시켜 문제 해결력 함양하는 데 목표를 둠

모든 학문은 AI로 통하라, MIT의 교육혁명

[질주하는 세계 - 대학] [1] 미국 MIT의 AI 칼리지
1조원 투입해 'AI 대학' 설립, 개교 158년 사상 최대 프로젝트
中 도전에 위기감… 역사·철학 등 인문계 학생들까지 융합교육

케임브리지(미국)=박건형 특파원
입력 2019.01.01 03:01

미국 매사추세츠공대(MIT) 본관 옆 스타타(Stata) 센터. 여러 개의 빌딩이 찌그러지고 기울어져 뭉쳐진 듯한 건물이다. 내부도 미로처럼 구부러져 쭉 뻗은 복도를 찾아보기 어렵다. MIT 최대 연구 조직 '컴퓨터과학·인공지능연구소(CSAIL)'는 이런 곳에 있었다. 애덤 코너 시몬스 CSAIL 커뮤니케이션 총괄은 "센터를 설계한 건축가 프랭크 게리가 과학자들이 자주 만나 의견을 듣고 함께 고민하고 융합하라는 뜻에서 복잡하게 만든 것"이라고 했다.

인공지능(AI)시대에 요구되는 능력

- **인공지능**이란 단순한 계산 기능뿐 아니라 **어떤 창조적인 처리 기능**을 갖추고 있는 경우가 많음
- 일반적으로 자율주행자동차나 로봇처럼 **'컴퓨터가 스스로 지적인 업무 처리를 하는 기기'**를 AI라고 표현

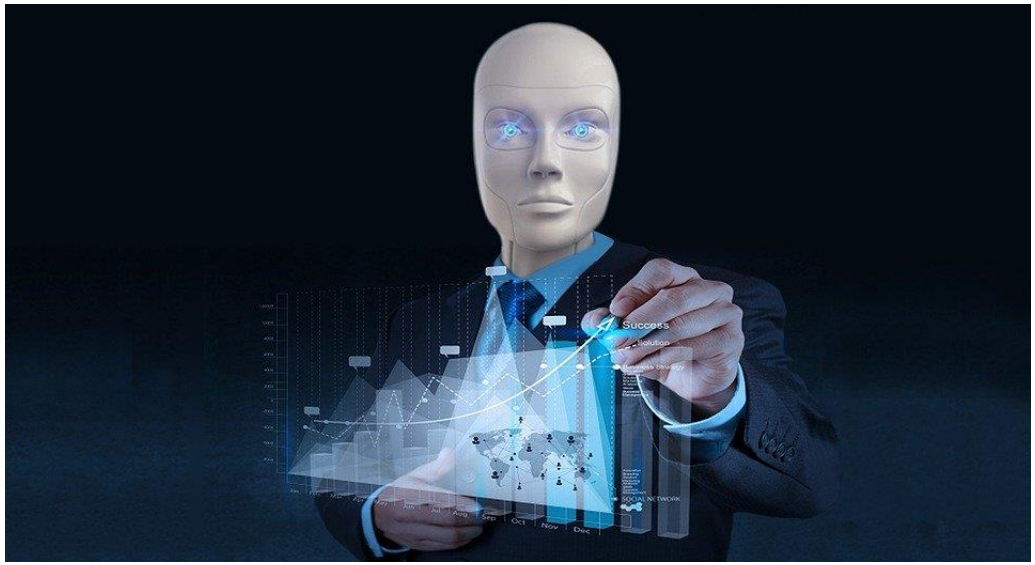

▪ 인공지능 시대에 요구되는 능력 (=AI 리터러시 능력)

- '인공지능 시대'를 맞아 우리 삶에서 직면하는 수많은 문제 상황에서 발전된 기술을 적절히 활용하기 위해서 그 기술이 어떤 것인지 이해하고 적절히 활용할 줄 아는 능력

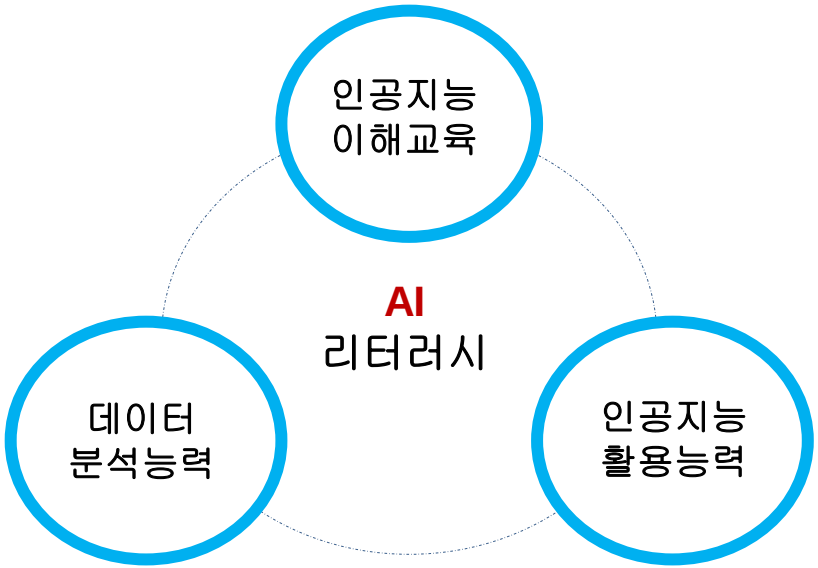

AI 리터러시 함양 측면
• 우리 삶의 변화를 가져온 인공지능을 이해하는 것 • 새로운 문제 상황에 인공지능을 적용할 줄 아는 것 • 데이터를 통해 현상을 파악하고 해결을 위한 시사점을 도출하는 것
전공별 AI 활용 측면
• 전공관련 산업분야의 문제 상황을 인식하고, 이를 해결하기 위하여 관련 데이터를 분석하는 것, 해결을 위한 시사점을 도출하는 것 • 문제해결을 위한 인공지능 활용 제안서를 작성하는 것

*리터러시(소양): 읽고 쓰기, 이해하고, 활용하는

- **빅데이터의 시대. 데이터 과학이라는 새로운 영역의 출현.**
  - 클라우드 컴퓨팅의 확산. 빅데이터 저장, 분석에 필요한 컴퓨팅 자원이 매우 저렴해짐.
  - 컴퓨팅 파워의 대중화는 최적의 학습환경과 연구 인프라를 제공.

- **데이터과학은 데이터를 연구하는 분야이고, 데이터 자체가 가장 중요한 자원**
  - 데이터 분석 업무의 80~90%는 데이터를 수집하고 정리하는 일이 차지.
  - 나머지 10~20%는 알고리즘을 선택하고, 모델링 결과를 분석하여 데이터로부터 유용한 정보(information)을 뽑아내는 분석 프로세스의 몫.
  - 데이터과학자가 하는 가장 중요한 일이 데이터를 수집하고 분석이 가능한 형태로 정리하는 것.

- **데이터의 중요성**
  - 미지의 사물(정보가 없는 사물)과 함께 자주 사용하는 사물(정보가 있는 사물)에서 미지의 사물에 대한 성질을 추측하는 방법

    -> 인공지능에서 중요한 원리

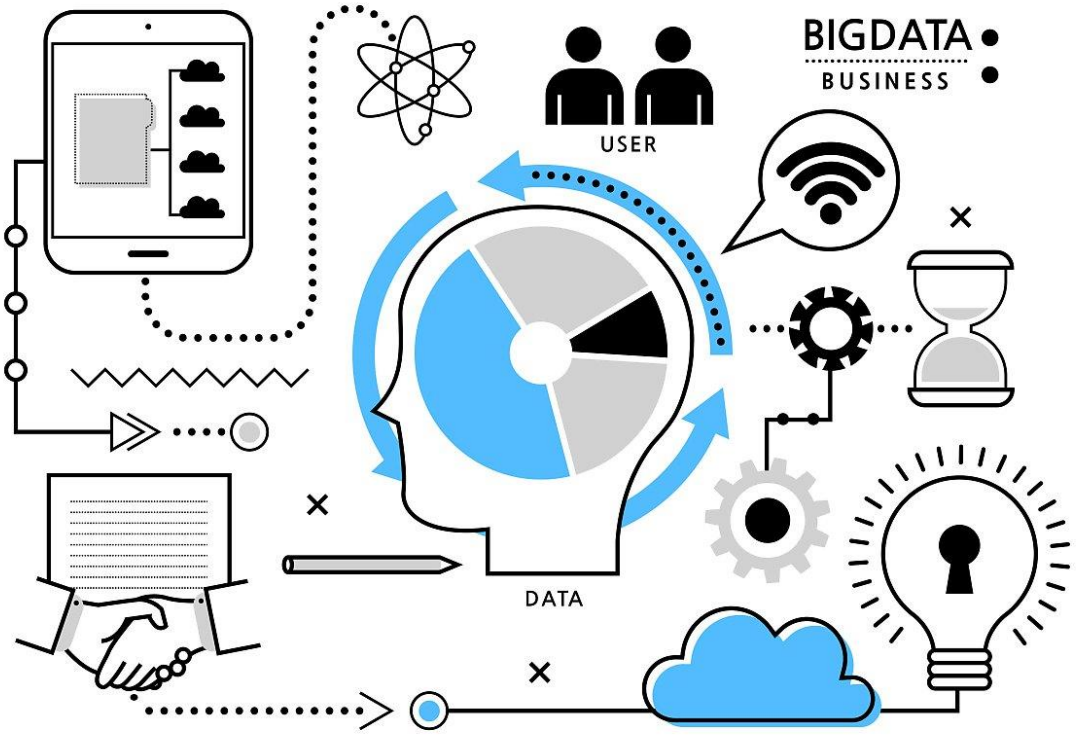

- **판다스는 데이터를 수집하고 정리하는데 최적화된 도구**
  - 가장 배우기 쉬운 프로그래밍 언어, 파이썬(Python) 기반.
  - 오픈소스(open source)로 무료로 이용 가능.

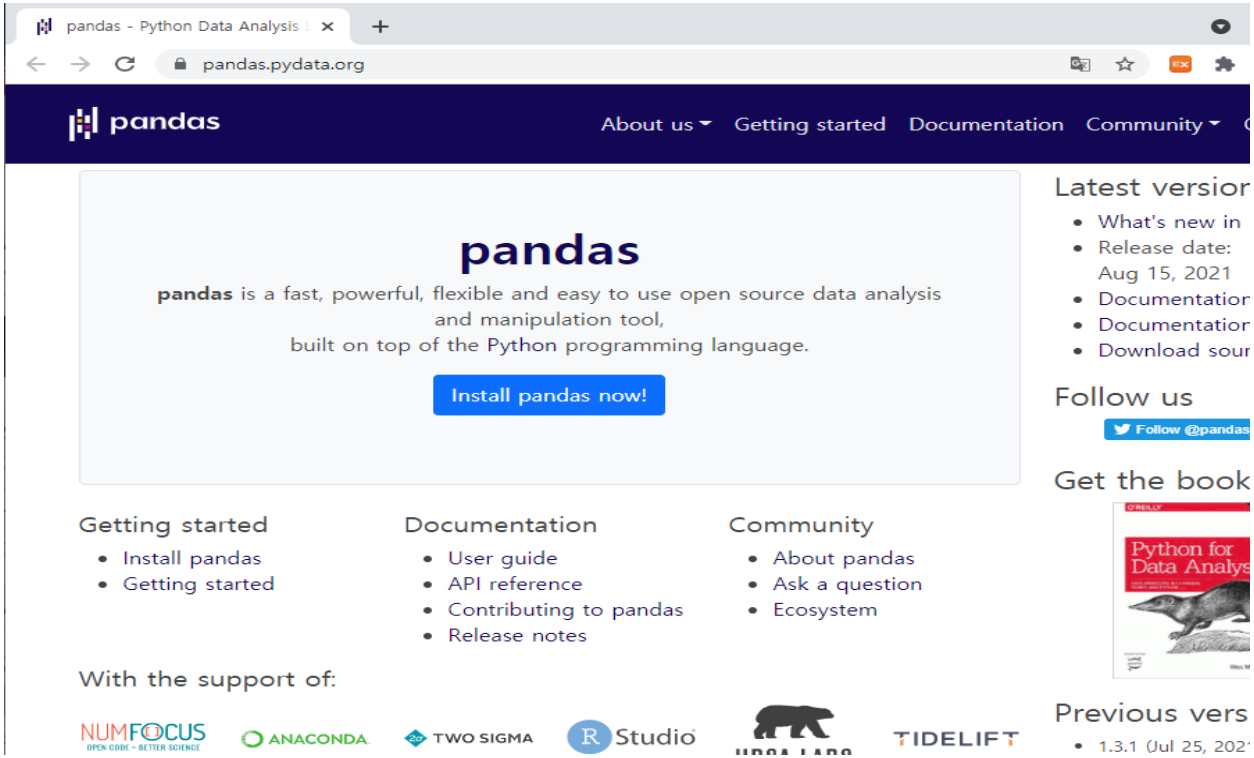

판다스 공식 홈페이지(http://pandas.pydata.org/)

▪ 목적

- 분석을 위해 다양한 소스(source)로부터 수집하는 데이터는 형태나 속성이 매우 다양함.
- 특히, 서로 다른 형식을 갖는 여러 종류의 데이터를 컴퓨터가 이해할 수 있도록 동일한 형식을 갖는 구조로 통합할 필요가 있음
- 판다스의 일차적인 목적은 **형식적으로 서로 다른 여러 가지 유형의 데이터를 공통의 포맷으로 정리**하는 것

▪ 종류

- 판다스는 **시리즈(Series)와 데이터프레임(DataFrame)이라는 구조화된 데이터 형식**을 제공함.
- 서로 다른 종류의 데이터를 한곳에 담는 그릇(컨테이너)이 됨.
- 시리즈는 1차원 배열이고, 데이터프레임이 2차원 배열이라는 점에서 차이. 특히, 행과 열로 이루어진 2차원 구조의 데이터프레임은 데이터 분석 실무에서 자주 사용.

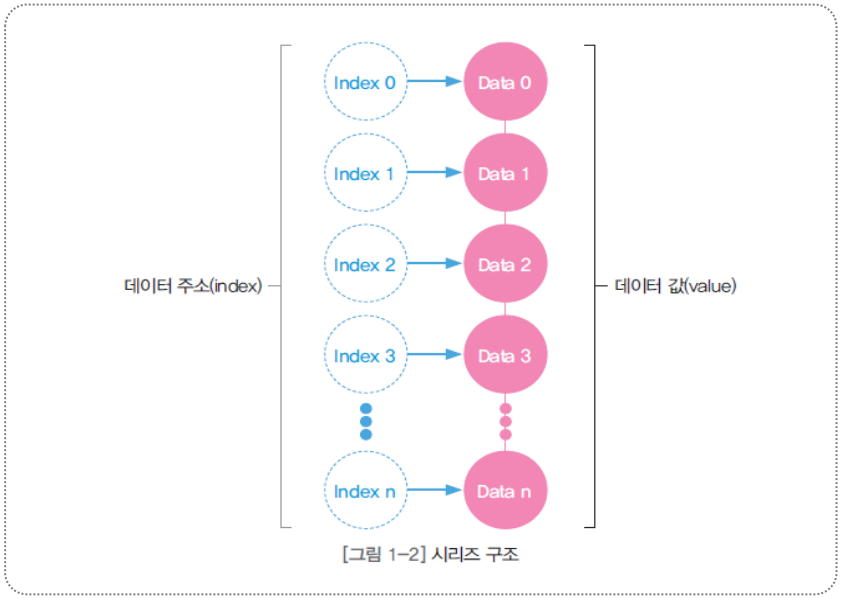

[그림 1-2] 시리즈 구조

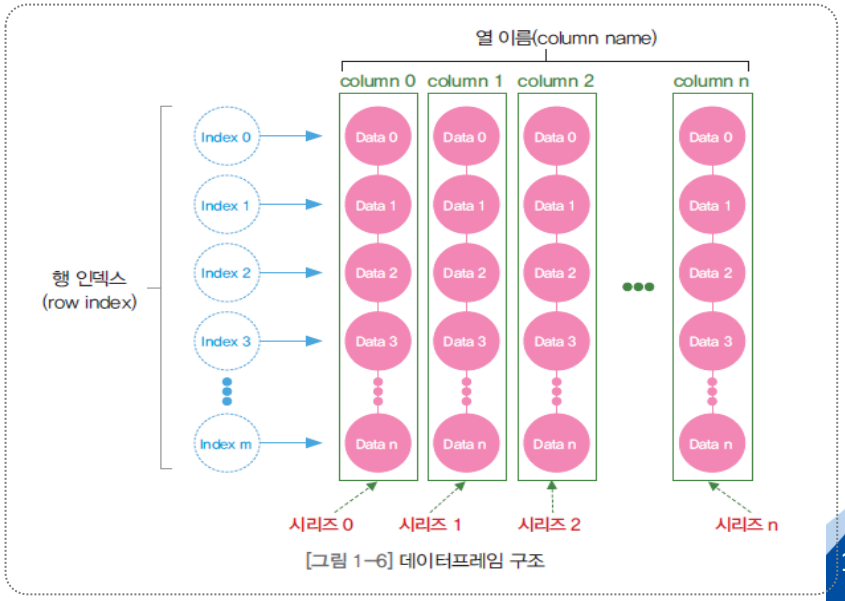

[그림 1-6] 데이터프레임 구조

2-1. 시리즈

▪ 시리즈 만들기

1) 딕셔너리와 시리즈의 구조가 비슷하기 때문에, **딕셔너리를 시리즈로 변환**하는 방법을 많이 사용.

2) 판다스 내장 함수인 Series()를 이용하고, 딕셔너리를 함수의 매개변수(인자)로 전달.

```
딕셔너리 → 시리즈 변환: pandas.Series( 딕셔너리 )
```

3) 딕셔너리의 키(k)는 시리즈의 인덱스에 대응하고, 딕셔너리의 각 키에 매칭되는 값(v)이 시리즈의 데이터 값(원소)로 변환.

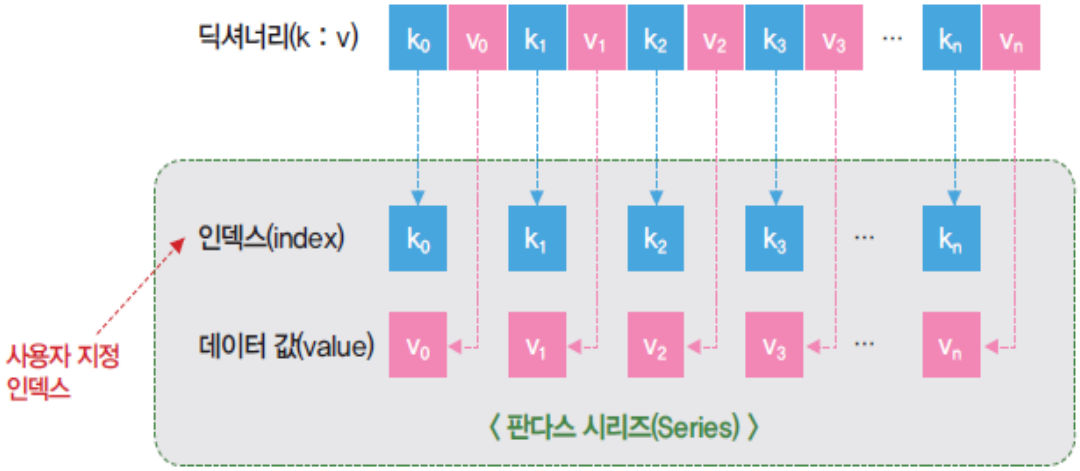

[그림 1-3] 딕셔너리 → 시리즈 변환

[예제 1-1]

딕셔너리를 시리즈로 변환해 본다. {'a': 1, 'b': 2, 'c': 3}와 같이 'k:v' 구조를 갖는 딕셔너리를 정의하여 변수 dict_data에 저장한다. 변수 dict_data에 저장되어 있는 딕셔너리를 Series() 함수의 인자로 전달하면, 시리즈로 변환한다. Series() 함수가 반환한 시리즈 객체를 변수 sr에 저장한다.

```
1  # -*- coding: utf-8 -*-
2
3  # pandas 불러오기
4  import pandas as pd
5
6  # key:value 쌍으로 딕셔너리를 만들고, 변수 dict_data에 저장
7  dict_data = {'a': 1, 'b': 2, 'c': 3}
8
9  # 판다스 Series() 함수로 dictionary를 Series로 변환. 변수 sr에 저장
10 sr = pd.Series(dict_data)
11
12 # sr의 자료형 출력
13 print(type(sr))
14 print('\n')
15 # 변수 sr에 저장되어 있는 시리즈 객체를 출력
16 print(sr)
```

〈실행 결과〉 코드 전부 실행

```
<class 'pandas.core.series.Series'>


a    1
b    2
c    3
dtype: int64
```

2-1. 시리즈

▪ 인덱스 구조

1) 인덱스는 자기와 짝을 이루는 **원소의 순서와 주소를 저장**.

2) 인덱스를 잘 활용하면 데이터 값의 탐색, 정렬, 선택, 결합 등 데이터 조작을 쉽게 할 수 있음.

3) **인덱스의 종류 (2가지)**

① 정수형 위치 인덱스(integer position)

② 인덱스 이름(index name) 또는 인덱스 라벨(index label)

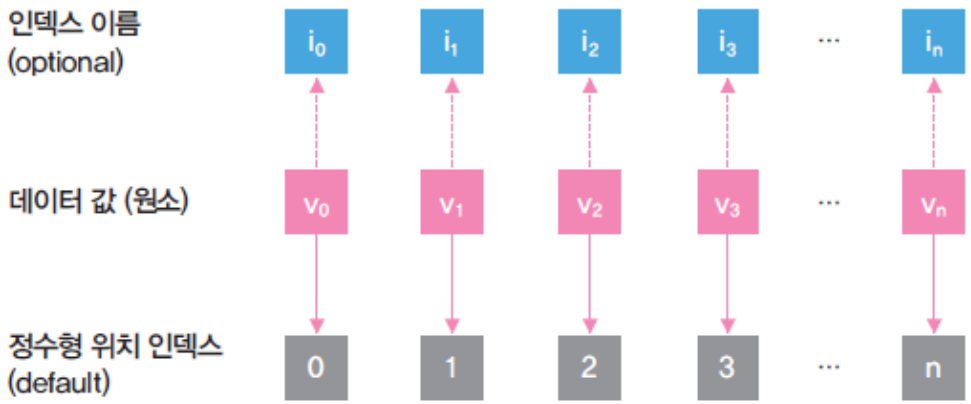

[그림 1-4] 시리즈 인덱스의 유형

[예제 1-2] ① 시리즈 만들기

파이썬 리스트를 시리즈로 변환해 본다. 단, 딕셔너리의 키처럼 인덱스로 변환될 값이 없다. 따라서, 인덱스를 별도로 정의하지 않으면, 디폴트로 정수형 위치 인덱스(0, 1, 2, …)가 자동 지정된다. 다음 예제에서는 0 ~ 4 범위의 정수값이 인덱스로 지정된다.

```
1  # -*- coding: utf-8 -*-
2
3  import pandas as pd
4
5  # 리스트를 시리즈로 변환하여 변수 sr에 저장
6  list_data = ['2019-01-02', 3.14, 'ABC', 100, True]
7  sr = pd.Series(list_data)
8  print(sr)
```

〈실행 결과〉 코드 1~8라인을 부분 실행

```
0    2019-01-02
1          3.14
2           ABC
3           100
4          True
dtype: object
```

[예제 1-2] ② 인덱스 vs. 데이터 값 배열 확인하기

시리즈의 index 속성과 values 속성을 이용하면, 인덱스 배열과 데이터 값의 배열을 불러올 수 있다. .

```
~  ~~~ 생략 ~~~

11  # 인덱스 배열은 변수 idx에 저장. 데이터 값 배열은 변수 val에 저장
12  idx = sr.index
13  val = sr.values
14  print(idx)
15  print('\n')
16  print(val)
```

〈실행 결과〉 코드 11~16라인을 부분 실행

```
RangeIndex(start=0, stop=5, step=1)



['2019-01-02' 3.14 'ABC' 100 True]
```

2-1. 시리즈

▪ 원소 선택

1) 인덱스를 이용하여, 시리즈의 원소를 선택.

2) 하나의 원소를 선택하거나, 여러 원소를 한꺼번에 선택 가능.

3) 인덱스 범위를 지정하여 여러 개의 원소 선택 가능.

4) 인덱스의 유형에 따라 사용법이 조금 다르다.

- 정수형 인덱스: 대괄호([ ]) 안에 숫자 입력. (0부터 시작)
- 인덱스 이름(라벨): 대괄호([ ]) 안에 이름과 함께 따옴표를 입력.
  (큰 따옴표(" "), 작은 따옴표(' ') 모두 사용)

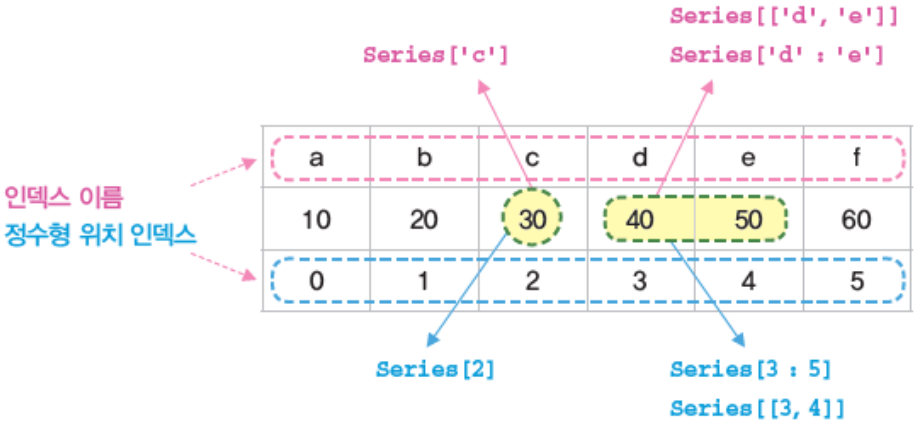

[그림 1-5] 시리즈 원소 선택

[예제 1-3] ① 시리즈 만들기

파이썬 튜플을 시리즈로 변환한다. 정수형 위치 인덱스 대신에 인덱스 이름을 따로 지정할 수 있다. Series() 함수의 index 옵션에 인덱스 이름을 리스트 형태로 직접 전달하는 방식이다.

```
1  # -*- coding: utf-8 -*-
2
3  import pandas as pd
4
5  # 투플을 시리즈로 변환(인덱스 옵션 지정)
6  tup_data = ('영인', '2010-05-01', '여', True)
7  sr = pd.Series(tup_data, index=['이름', '생년월일', '성별', '학생여부'])
8  print(sr)
```

〈실행 결과〉 코드 1~8라인을 부분 실행

```
이름              영인
생년월일    2010-05-01
성별              여
학생여부         True
dtype: object
```

[예제 1-3] ② 원소 1개 선택

인덱스를 이용하여 원소를 선택할 때는 대괄호([ ]) 안에 인덱스를 입력한다. 시리즈의 첫 번째 데이터를 선택하기 위해 정수형 위치 인덱스(0)와 첫 번째 위치에 있는 인덱스 라벨('이름')을 입력한다.

```
~  ~~~ 생략 ~~~

11  # 원소를 1개 선택
12  print(sr[0])        # sr의 1번째 원소를 선택(정수형 위치 인덱스)
13  print(sr['이름'])   # '이름' 라벨을 가진 원소를 선택(인덱스 이름)
```

〈실행 결과〉 코드 11~13라인을 부분 실행

```
영인
영인
```

[예제 1-3] ③ 여러 개의 원소를 선택(인덱스 리스트 활용)

여러 개의 인덱스를 리스트 형태로 대괄호([ ]) 안에 입력하면, 짝을 이루는 원소 데이터를 모두 반환한다.
정수형 위치 인덱스는 0부터 시작하기 때문에 2번째 인덱스 이름인 '생년월일'은 정수형 인덱스 1을 사용하고, 3번째 인덱스 이름인 '성별'은 정수형 인덱스 2를 사용한다.

```
 ~  ~~~ 생략 ~~~

16  # 여러 개의 원소를 선택(인덱스 리스트 활용)
17  print(sr[[1, 2]])
18  print('\n')
19  print(sr[['생년월일', '성별']])
```

〈실행 결과〉 코드 16~19라인을 부분 실행

```
생년월일    2010-05-01
성별             여
dtype: object


생년월일    2010-05-01
성별             여
dtype: object
```

[예제 1-3] ④ 여러 개의 원소를 선택(인덱스 범위 지정)

22번 라인의 sr[1 : 2] 에서 정수형 위치 인덱스를 사용할 때는, 범위의 끝(2)이 포함되지 않는다 **('성별' 불포함).**
그러나, 21번 라인의 sr['생년월일' : '성별'] 과 같이, 인덱스 이름을 사용하면 **범위의 끝('성별')이 포함된다.**

```
 ~  ~~~ 생략 ~~~

22  # 여러 개의 원소를 선택(인덱스 범위 지정)
23  print(sr[1 : 2])
24  print('\n')
25  print(sr['생년월일' : '성별'])
```

〈실행 결과〉 코드 22~25라인을 부분 실행

```
생년월일    2010-05-01
dtype: object


생년월일    2010-05-01
성별              여
dtype: object
```

2-2. 데이터프레임

▪ 개요

1) 데이터프레임은 2차원 배열. R의 데이터프레임에서 유래.

2) 데이터프레임의 열은 시리즈 객체. 시리즈를 열벡터(vector)라고 하면,
데이터프레임은 여러 개의 열벡터들이 같은 행 인덱스를 기준으로 줄지어 결합된
2차원 벡터 또는 행렬(matrix).

3) 데이터프레임은 행과 열을 나타내기 위해 두 가지 종류의 주소를 사용.
행 인덱스(row index)와 열 이름(column name 또는 column label)으로 구분.

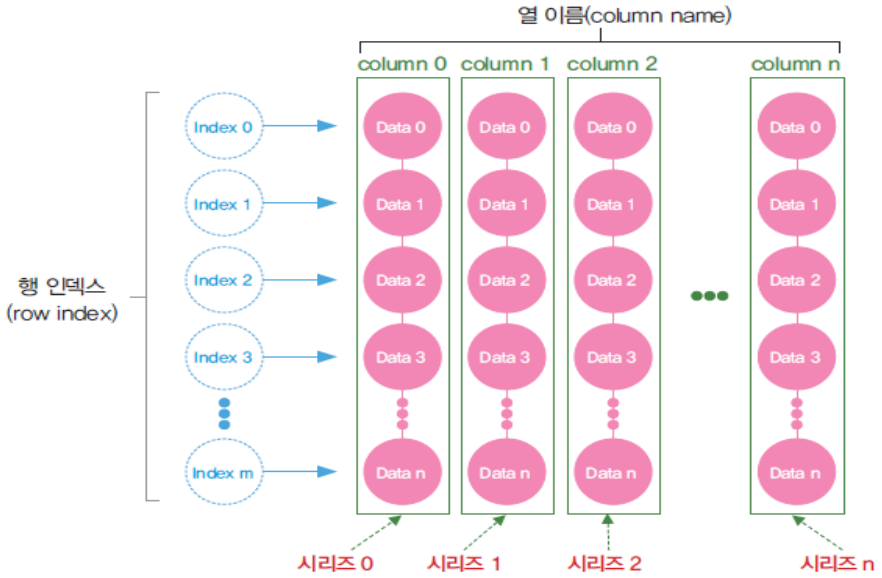

[그림 1-6] 데이터프레임 구조

2-2. 데이터프레임

▪ 개요

4) 데이터프레임의 각 열은 공통의 속성을 갖는 일련의 데이터를 나타냄.

5) 각 행은 개별 관측대상에 대한 다양한 속성 데이터들의 모음인 레코드(record).

열 →

종목 코드	회사 이름	액면가	총 주식수
005930	삼성전자	100원	5,970백만 주
017670	SK텔레콤	500원	81백만 주
005380	현대자동차	5000원	214백만 주

행 ←

[표 1-1] 주식 종목 리스트

- 주식종목 리스트에서, 각 행은 하나의 주식종목에 관한 **관측값(observation)**을 나타냄
- 각 열은 종목코드, 회사이름, 액면가, 총주식수 등 공통의 속성이나 범주를 나타내는데, 보통 **변수(variable)**로 활용됨

2-2. 데이터프레임

▪ 데이터프레임 만들기

1) 같은 길이(원소의 개수가 동일한)의 배열 여러 개가 필요.
데이터프레임은 여러 개의 시리즈(열, column)를 모아 놓은 집합.

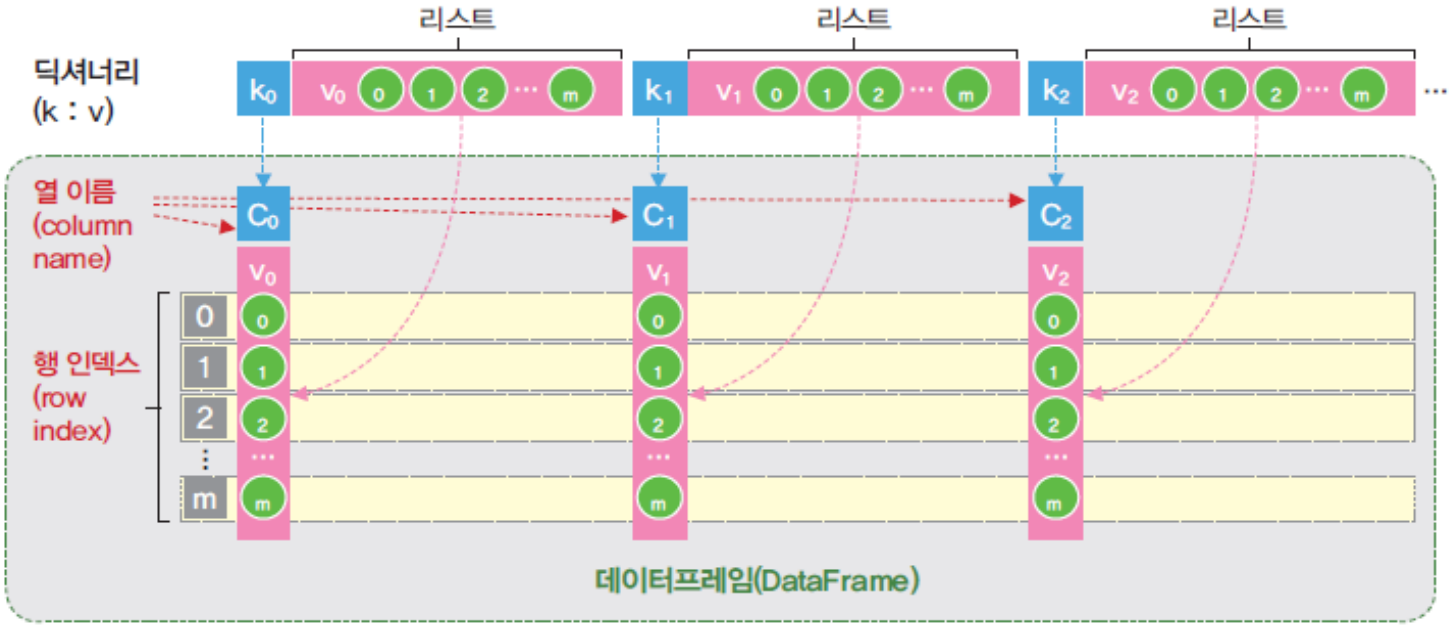

[그림 1-7] 딕셔너리 → 데이터프레임 변환

2-2. 데이터프레임

▪ 데이터프레임 만들기

2) 판다스 DataFrame() 함수를 사용. 여러 개의 리스트를 원소로 갖는 딕셔너리를 함수에 전달하는 방식을 주로 활용.

딕셔너리 → 데이터프레임 변환: `pandas.DataFrame( 딕셔너리 객체 )`

3) 딕셔너리의 값(v)에 해당하는 각 리스트가 시리즈로 변환되어 데이터프레임의 각 열이 됨.

4) 딕셔너리의 키(k)는 각 시리즈의 이름으로 변환되어, 최종적으로 데이터프레임의 열 이름이 됨.

[예제 1-4]

원소 3개씩 담고 있는 리스트를 5개 만든다. 이들 5개의 리스트를 원소로 갖는 딕셔너리를 정의하고, 판다스 DataFrame() 함수에 전달하면 5개의 열을 갖는 데이터프레임을 만든다.
이때, 딕셔너리의 키(k)가 열 이름(c0 ~ c4)이 되고, 값(v)에 해당하는 각 리스트가 데이터프레임의 열이 된다. 행 인덱스에는 정수형 위치 인덱스(0, 1, 2)가 자동 지정된다.

```
1  # -*- coding: utf-8 -*-
2
3  import pandas as pd
4
5  # 열이름을 key로 하고, 리스트를 value로 갖는 딕셔너리 정의(2차원 배열)
6  dict_data = {'c0':[1,2,3], 'c1':[4,5,6], 'c2':[7,8,9], 'c3':[10,11,12], 'c4':[13,14,15]}
7
8  # 판다스 DataFrame() 함수로 딕셔너리를 데이터프레임으로 변환. 변수 df에 저장
9  df = pd.DataFrame(dict_data)
10
11 # df의 자료형 출력
12 print(type(df))
13 print('\n')
14 # 변수 df에 저장되어 있는 데이터프레임 객체를 출력
15 print(df)
```

〈실행 결과〉 코드 전부 실행

```
<class 'pandas.core.frame.DataFrame'>


   c0  c1  c2  c3  c4
0   1   4   7  10  13
1   2   5   8  11  14
2   3   6   9  12  15
```

2-2. 데이터프레임

▪ 행 인덱스/열 이름 설정

- 데이터프레임의 행 인덱스와 열 이름을 사용자가 지정 가능.

```
행 인덱스/열 이름 설정: pandas.DataFrame( 2차원 배열,
                                          index=행 인덱스 배열,
                                          columns=열 이름 배열 )
```

[예제 1-5] ① 데이터프레임을 만들 때 설정

'3개의 원소를 갖는 리스트' 2개를 원소로 갖는 리스트(2차원 배열)로 데이터프레임을 만든다.
이때, 각 리스트가 행으로 변환되는 점에 유의한다.

- index 옵션: **['준서', '예은']** 배열을 지정
- columns 옵션: **['나이', '성별', '학교']** 배열을 지정

```
1  # -*- coding: utf-8 -*-
2
3  import pandas as pd
4
5  # 행 인덱스/열 이름 지정하여 데이터프레임 만들기
6  df = pd.DataFrame([[15, '남', '덕영중'], [17, '여', '수리중']],
7                    index=['준서', '예은'],
8                    columns=['나이', '성별', '학교'])
9
10 # 행 인덱스, 열 이름 확인하기
11 print(df)          # 데이터프레임
12 print('\n')
13 print(df.index)    # 행 인덱스
14 print('\n')
15 print(df.columns)  # 열 이름
```

〈실행 결과〉 코드 1~15라인을 부분 실행

```
      나이 성별  학교
준서   15  남  덕영중
예은   17  여  수리중

Index(['준서', '예은'], dtype='object')


Index(['나이', '성별', '학교'], dtype='object')
```

[예제 1-5] ② 속성을 지정하여 변경하기

데이터프레임 df의 행 인덱스 배열을 나타내는 df.index와 열 이름 배열을 나타내는 df.columns에 새로운 배열을 할당하는 방식으로, 행 인덱스와 열 이름을 변경할 수 있다.

- **행 인덱스 변경:** `DataFrame 객체.index = 새로운 행 인덱스 배열`
- **열 이름 변경:** `DataFrame 객체.columns = 새로운 열 이름 배열`

```
~  ~~~ 생략 ~~~

18  # 행 인덱스, 열 이름 변경하기
19  df.index=['학생1', '학생2']
20  df.columns=['연령', '남녀', '소속']
21
22  print(df)          # 데이터프레임
23  print('\n')
24  print(df.index)    # 행 인덱스
25  print('\n')
26  print(df.columns)  # 열 이름
```

〈실행 결과〉 코드 18~26라인을 부분 실행

```
      연령  남녀   소속
학생1   15   남  덕영중
학생2   17   여  수리중


Index(['학생1', '학생2'], dtype='object')


Index(['연령', '남녀', '소속'], dtype='object')
```

[예제 1-6] ③ rename 메소드 사용

rename() 메소드를 적용하면, 행 인덱스 또는 열 이름의 일부를 선택하여 변경 가능.
단, 원본 객체를 직접 수정하는 것이 아니라 새로운 데이터프레임 객체를 반환하는 점 유의~!
* 원본 객체를 변경하려면, inplace=True 옵션을 사용.

- 행 인덱스 변경: `DataFrame 객체.rename(index={기존 인덱스:새 인덱스, … })`
- 열 이름 변경: `DataFrame 객체.rename(columns={기존 이름:새 이름, … })`

```
3  import pandas as pd
4
5  # 행 인덱스/열 이름 지정하여 데이터프레임 만들기
6  df = pd.DataFrame([[15, '남', '덕영중'], [17, '여', '수리중']],
7                    index=['준서', '예은'],
8                    columns=['나이', '성별', '학교'])
9
10 # 데이터프레임 df 출력
11 print(df)
12 print("\n")
13
14 # 열 이름 중, '나이'를 '연령'으로, '성별'을 '남녀'로, '학교'를 '소속'으로 바꾸기
15 df.rename(columns={'나이':'연령', '성별':'남녀', '학교':'소속'}, inplace=True)
16
17 # df의 행 인덱스 중에서, '준서'를 '학생1'로, '예은'을 '학생2'로 바꾸기
18 df.rename(index={'준서':'학생1', '예은':'학생2' }, inplace=True)
19
20 # df 출력(변경 후)
21 print(df)
```

〈실행 결과〉 코드 전부 실행

```
      나이 성별   학교
준서   15  남  덕영중
예은   17  여  수리중


      연령 남녀   소속
학생1   15  남  덕영중
학생2   17  여  수리중
```

2-2. 데이터프레임

▪ 행/열 삭제

- drop() 메소드에 행을 삭제할 때는 축(axis) 옵션으로 axis=0을 입력하거나, 별도로 입력하지 않음
- 반면, 축옵션으로 axis=1을 입력하면 열을 삭제함. 동시에 여러 개의 행 또는 열을 삭제하려면, 리스트 형태로 입력함

```
• 행 삭제: DataFrame 객체.drop(행 인덱스 또는 배열, axis=0)
• 열 삭제: DataFrame 객체.drop(열 이름 또는 배열, axis=1)
```

- 한편, drop() 메소드는 기존 객체를 변경하지 않고 새로운 객체를 반환하는 점에 유의~! 따라서, 원본 객체를 직접 변경하기 위해서는, inplace=True 옵션을 추가함

[예제 1-7] ① 행 삭제

df

	수학	영어	음악	체육
서준	90	98	85	100
우현	80	89	95	90
인아	70	95	100	90

```
df.drop('우현', inplace=True)
```

	수학	영어	음악	체육
서준	90	98	85	100
인아	70	95	100	90

```
df.drop(['우현', '인아'], axis=0, inplace=True)
```

	수학	영어	음악	체육
서준	90	98	85	100

[그림 1-9] 행 삭제

[예제 1-7] ① 행 삭제

```
3  import pandas as pd
4
5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
6  exam_data = {'수학' : [ 90, 80, 70], '영어' : [ 98, 89, 95],
7               '음악' : [ 85, 95, 100], '체육' : [ 100, 90, 90]}
8
9  df = pd.DataFrame(exam_data, index=['서준', '우현', '인아'])
10 print(df)
11 print('\n')
12
13 # 데이터프레임 df를 복제하여 변수 df2에 저장. df2의 1개 행(row) 삭제
14 df2 = df[:]
15 df2.drop('우현', inplace=True)
16 print(df2)
17 print('\n')
18
19 # 데이터프레임 df를 복제하여 변수 df3에 저장. df3의 2개 행(row) 삭제
20 df3 = df[:]
21 df3.drop(['우현', '인아'], axis=0, inplace=True)
22 print(df3)
```

〈실행 결과〉 코드 전부 실행

	수학	영어	음악	체육
서준	90	98	85	100
우현	80	89	95	90
인아	70	95	100	90

	수학	영어	음악	체육
서준	90	98	85	100
인아	70	95	100	90

	수학	영어	음악	체육
서준	90	98	85	100

[예제 1-8] ② 열 삭제

df

	수학	영어	음악	체육
서준	90	98	85	100
우현	80	89	95	90
인아	70	95	100	90

```
df.drop('수학', axis=1, inplace=True)
```

	영어	음악	체육	
서준	98	85	100	
우현	89	95	90	
인아	95	100	90	

```
df.drop(['영어', '음악'], axis=1, inplace=True)
```

	수학	체육		
서준	90	100		
우현	80	90		
인아	70	90		

[그림 1-10] 열 삭제

[예제 1-8] ② 열 삭제

```
3  import pandas as pd
4
5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
6  exam_data = {'수학' : [ 90, 80, 70], '영어' : [ 98, 89, 95],
7               '음악' : [ 85, 95, 100], '체육' : [ 100, 90, 90]}
8
9  df = pd.DataFrame(exam_data, index=['서준', '우현', '인아'])
10 print(df)
11 print('\n')
12
13 # 데이터프레임 df를 복제하여 변수 df4에 저장. df4의 1개 열(column) 삭제
14 df4 = df[:]
15 df4.drop('수학', axis=1, inplace=True)
16 print(df4)
17 print('\n')
19 # 데이터프레임 df를 복제하여 변수 df5에 저장. df5의 2개 열(column) 삭제
20 df5 = df[:]
21 df5.drop(['영어', '음악'], axis=1, inplace=True)
22 print(df5)
```

〈실행 결과〉 코드 전부 실행

	수학	영어	음악	체육
서준	90	98	85	100
우현	80	89	95	90
인아	70	95	100	90

	영어	음악	체육
서준	98	85	100
우현	89	95	90
인아	95	100	90

	수학	체육
서준	90	100
우현	80	90
인아	70	90

2-2. 데이터프레임

▪ 행 선택

1) **loc**과 **iloc** 인덱서를 사용.

2) 인덱스 이름을 기준으로 행을 선택할 때는 loc을 이용하고, 정수형 위치 인덱스를 사용할 때는 iloc을 이용.

구분	loc	iloc
탐색 대상	인덱스 이름(index label)	정수형 위치 인덱스(integer position)
범위 지정	가능(범위의 끝 포함) 예) `['a':'c']` → `'a',' b', 'c'`	가능(범위의 끝 제외) 예) `[3:7]` → `3, 4, 5, 6` (* 7 제외)

[표 1-2] loc과 iloc

[예제 1-9] ① 1개의 행 선택

데이터프레임의 첫 번째 행에는 '서준' 학생의 과목별 점수 데이터가 입력되어 있다. '서준' 학생의 과목별 점수 데이터를 행으로 추출하면 시리즈 객체가 반환된다.
loc 인덱서를 이용하려면 '서준'이라는 인덱스 이름을 직접 입력하고, iloc을 이용할 때는 첫 번째 정수형 위치를 나타내는 0을 입력한다. 각각 반환되는 값을 label1 변수와 position1 변수에 저장, 출력하면 같은 결과를 갖는다.

```
3  import pandas as pd
4
5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
6  exam_data = {'수학' : [ 90, 80, 70], '영어' : [ 98, 89, 95],
7               '음악' : [ 85, 95, 100], '체육' : [ 100, 90, 90]}
8
9  df = pd.DataFrame(exam_data, index=['서준', '우현', '인아'])
10 print(df)
11 print('\n')
12
13 # 행 인덱스를 사용하여 행 1개 선택
14 label1 = df.loc['서준']
15 position1 = df.iloc[0]
16 print(label1)
17 print('\n')
18 print(position1)
```

〈실행 결과〉 코드 1~18라인을 부분 실행

```
     수학  영어  음악  체육
서준  90   98   85   100
우현  80   89   95   90
인아  70   95   100  90


수학    90
영어    98
음악    85
체육    100
Name: 서준, dtype: int64


수학    90
영어    98
음악    85
체육    100
Name: 서준, dtype: int64
```

[예제 1-9] ② 여러 개의 행을 선택(인덱스 리스트 활용)

2개 이상의 행 인덱스를 배열로 입력하면, 매칭되는 모든 행 데이터를 동시에 추출한다.
데이터프레임 df의 첫번째와 두번째 행에 있는 '서준', '우현' 학생을 인덱싱으로 선택해 본다.
loc 인덱서는 ['서준', '우현'] 과 같이 인덱스 이름을 배열로 전달하고, iloc을 이용할 때는 [0, 1] 과 같이 정수형 위치를 전달한다. 이때, label2 변수와 position2 변수에 저장된 값은 같다.

```
 ~  ~~~ (생략) ~~~

21  # 행 인덱스를 사용하여 2개 이상의 행 선택
22  label2 = df.loc[['서준', '우현']]
23  position2 = df.iloc[[0, 1]]
24  print(label2)
25  print('\n')
26  print(position2)
```

〈실행 결과〉 코드 21~26라인을 부분 실행

```
      수학  영어  음악  체육
서준   90    98    85   100
우현   80    89    95    90

      수학  영어  음악  체육
서준   90    98    85   100
우현   80    89    95    90
```

[예제 1-9] ③ 여러 개의 원소를 선택(인덱스 범위 지정)

행 인덱스의 범위를 지정하여 여러 개의 행을 동시에 선택하는 슬라이싱 기법을 사용한다.
단, 인덱스 이름을 범위로 지정한 label3의 경우에는 범위의 마지막 값인 '우현' 학생의 점수가 포함되지만, 정수형 위치 인덱스를 사용한 position3에는 범위의 마지막 값인 '우현' 학생의 점수가 제외된다.

```
 ~  ~~~ (생략) ~~~

29  # 행 인덱스의 범위를 지정하여 행 선택
30  label3 = df.loc['서준':'우현']
31  position3 = df.iloc[0:1]
32  print(label3)
33  print('\n')
34  print(position3)
```

〈실행 결과〉 코드 29~34라인을 부분 실행

```
      수학   영어   음악   체육
서준   90     98     85     100
우현   80     89     95      90


      수학   영어   음악   체육
서준   90     98     85     100
```

2-2. 데이터프레임

▪ 열 선택

- 열 데이터를 1개만 선택할 때는, 대괄호([ ]) 안에 열 이름을 따옴표와 함께 입력하거나 도트(.) 다음에 열 이름을 입력하는 두 가지 방식을 사용함.
- 두 번째 방법은 반드시 열 이름이 문자열일 경우에만 가능함

열 1개 선택(시리즈 생성): `DataFrame 객체["열 이름"]` 또는 `DataFrame 객체.열 이름`

	이름	수학	영어	음악	체육
0	서준	90	98	85	100
1	우현	80	89	95	90
2	인아	70	95	100	90

`df['수학']`

	수학
0	90
1	80
2	70

시리즈

`df[['음악', '체육']]`

	음악	체육
0	85	100
1	95	90
2	100	90

데이터프레임

[그림 1-11] 데이터프레임의 열 선택

[예제 1-10] ① 1개의 열 선택

type( ) 함수를 사용하여, 데이터프레임에서 1개의 열을 선택할 때 반환되는 객체의 자료형을 확인하면 시리즈이다.

```
3  import pandas as pd
4
5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
6  exam_data = {'이름' : [ '서준', '우현', '인아'],
7               '수학' : [ 90, 80, 70],
8               '영어' : [ 98, 89, 95],
9               '음악' : [ 85, 95, 100],
10              '체육' : [ 100, 90, 90]}
11 df = pd.DataFrame(exam_data)
12 print(df)
```

```
13 print(type(df))
14 print('\n')
15
16 # '수학' 점수 데이터만 선택. 변수 math1에 저장
17 math1 = df['수학']
18 print(math1)
19 print(type(math1))
20 print('\n')
21
22 # '영어' 점수 데이터만 선택. 변수 english에 저장
23 english = df.영어
24 print(english)
25 print(type(english))
```

〈실행 결과〉 코드 1~25라인을 부분 실행

```
   이름  수학  영어  음악  체육
0  서준   90   98   85  100
1  우현   80   89   95   90
2  인아   70   95  100   90
<class 'pandas.core.frame.DataFrame'>


0    90
1    80
2    70
Name: 수학, dtype: int64
<class 'pandas.core.series.Series'>


0    98
1    89
2    95
Name: 영어, dtype: int64
<class 'pandas.core.series.Series'>
```

[예제 1-10] ② n개의 열 선택 (리스트 입력)

열 n개 선택(데이터프레임 생성): DataFrame 객체[[열1, 열2 , … , 열n]]

대괄호 안에 열 이름의 리스트를 입력하면 리스트의 원소인 열을 모두 선택하여 데이터프레임으로 반환한다. 리스트의 원소로 열 이름 한 개만 있는 경우에도, 2중 대괄호([[ ]])를 사용하는 것이 되어 반환되는 객체가 시리즈가 아니라 데이터프레임이 된다.

```
~  ~~~ (생략) ~~~

28  # '음악', '체육' 점수 데이터를 선택. 변수 music_gym에 저장
29  music_gym = df[['음악', '체육']]
30  print(music_gym)
31  print(type(music_gym))
32  print('\n')
33
34  # '수학' 점수 데이터만 선택. 변수 math2에 저장
35  math2 = df[['수학']]
36  print(math2)
37  print(type(math2))
```

〈실행 결과〉 코드 28~37라인을 부분 실행

```
   음악  체육
0   85  100
1   95   90
2  100   90
<class 'pandas.core.frame.DataFrame'>


   수학
0  90
1  80
2  70
<class 'pandas.core.frame.DataFrame'>
```

2-2. 데이터프레임

▪ 원소 선택

- 데이터프레임의 행 인덱스와 열 이름을 [행, 열] 형식의 2차원 좌표로 입력하여 원소 위치를 지정하는 방법
- 원소가 위치하는 행과 열의 좌표를 입력하면 해당 위치의 원소가 반환됨
- 1개의 행과 2개 이상의 열을 선택하거나 반대로 2개 이상의 행과 1개의 열을 선택하는 경우 시리즈 객체가 반환됨.
- 2개 이상의 행과 2개 이상의 열을 선택하면 데이터프레임 객체를 반환함.

인덱스 이름 : DataFrame 객체.loc[행 인덱스, 열 이름]

정수 위치 인덱스 : DataFrame 객체.iloc[행 번호, 열 번호]

2-2. 데이터프레임

▪ 원소 선택

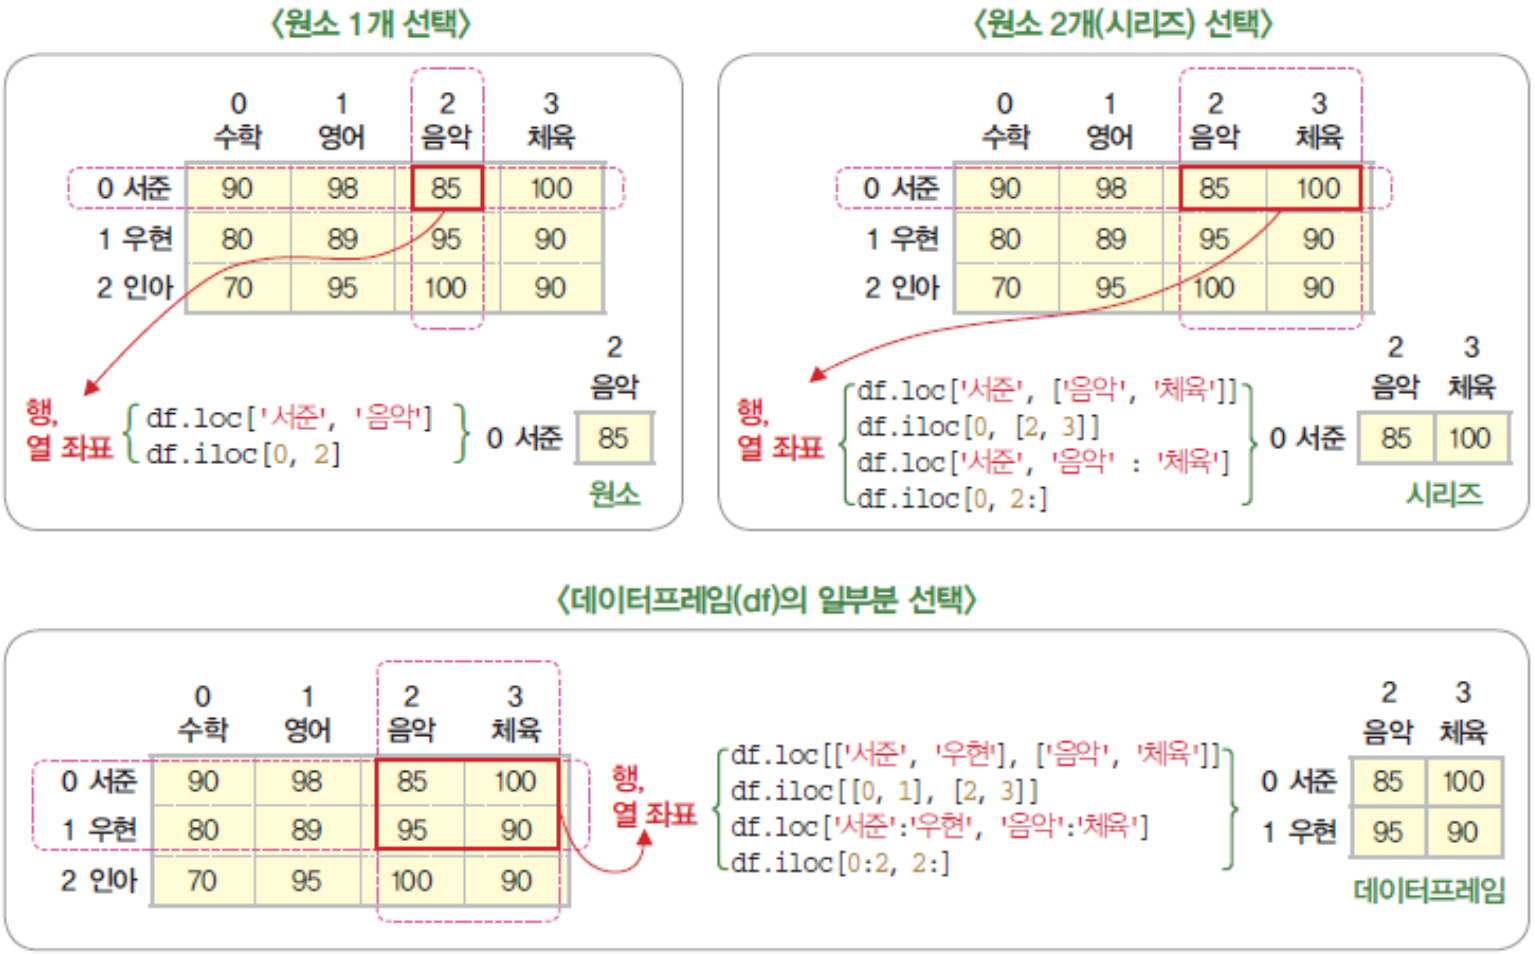

[그림 1-12] 데이터프레임의 [행, 열] 데이터 선택

[예제 1-11] ① 1개의 원소를 선택

```
 3  import pandas as pd
 4
 5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
 6  exam_data = {'이름' : [ '서준', '우현', '인아'],
 7               '수학' : [ 90, 80, 70],
 8               '영어' : [ 98, 89, 95],
 9               '음악' : [ 85, 95, 100],
10               '체육' : [ 100, 90, 90]}
11  df = pd.DataFrame(exam_data)
12
13  # '이름' 열을 새로운 인덱스로 지정하고, df 객체에 변경 사항 반영
14  df.set_index('이름', inplace=True)
15  print(df)
```

```
18  # 데이터프레임 df의 특정 원소 1개 선택('서준'의 '음악' 점수)
19  a = df.loc['서준', '음악']
20  print(a)
21  b = df.iloc[0, 2]
22  print(b)
```

- set_index () 메소드 : 인덱스가 될 열의 이름을 지정
- '이름' 열을 새로운 행 인덱스로 지정함
- '이름'열에 들어 있는 학생 3명의 이름이 행 인덱스 자리에 들어감.

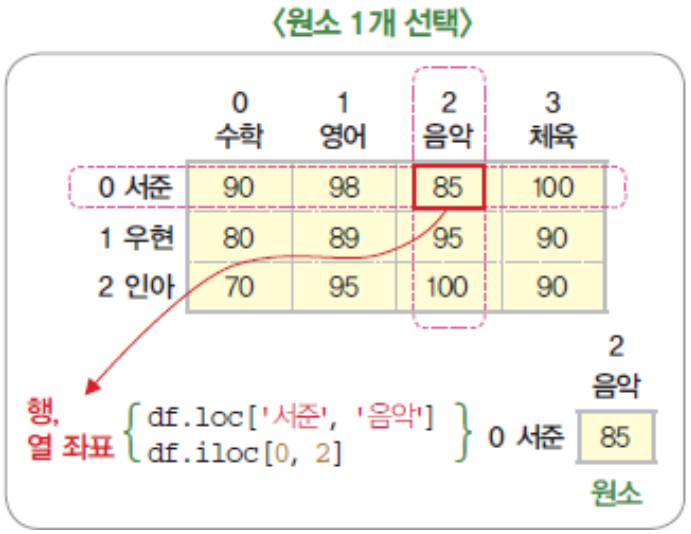

〈실행 결과〉 코드 18~22라인을 부분 실행

```
85
85
```

[예제 1-11] ② 2개 이상의 원소를 선택 (시리즈)

```
~  ~~~ 생략 ~~~

25  # 데이터프레임 df의 특정 원소 2개 이상 선택('서준'의 '음악', '체육' 점수)
26  c = df.loc['서준', ['음악', '체육']]
27  print(c)
28  d = df.iloc[0, [2, 3]]
29  print(d)
30  e = df.loc['서준', '음악':'체육']
31  print(e)
32  f = df.iloc[0, 2:]
33  print(f)
```

〈원소 2개(시리즈) 선택〉

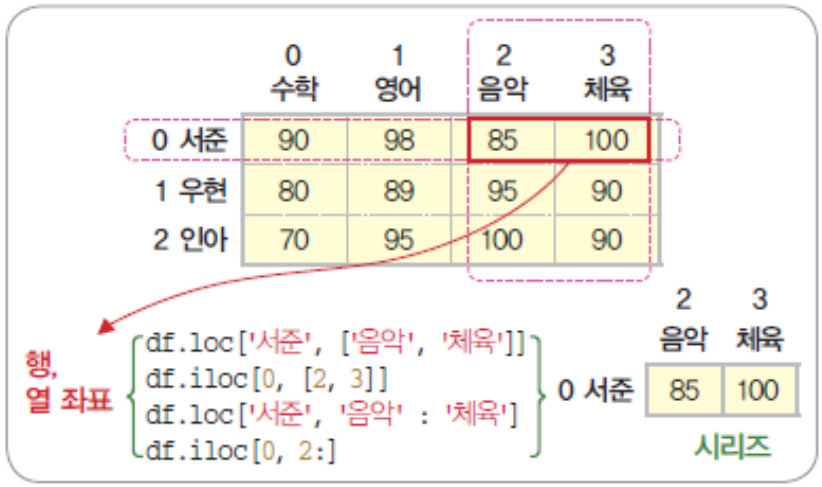

〈실행 결과〉 코드 25~33라인을 부분 실행

```
음악     85
체육    100
Name: 서준, dtype: int64
음악     85
체육    100
Name: 서준, dtype: int64
음악     85
체육    100
Name: 서준, dtype: int64
음악     85
체육    100
Name: 서준, dtype: int64
```

[예제 1-11] ③ 2개 이상의 원소를 선택 (데이터프레임)

```
~  ~~~ 생략 ~~~

36  # df 2개 이상의 행과 열에 속하는 원소들 선택('서준', '우현'의 '음악', '체육' 점수)
37  g = df.loc[['서준', '우현'], ['음악', '체육']]
38  print(g)
39  h = df.iloc[[0, 1], [2, 3]]
40  print(h)
41  i = df.loc['서준':'우현', '음악':'체육']
42  print(i)
43  j = df.iloc[0:2, 2:]
44  print(j)
```

〈실행 결과〉 코드 36~44라인을 부분 실행

```
      음악   체육
이름
서준   85   100
우현   95    90
      음악   체육
이름
서준   85   100
우현   95    90
      음악   체육
이름
서준   85   100
우현   95    90
      음악   체육
이름
서준   85   100
우현   95    90
```

〈데이터프레임(df)의 일부분 선택〉

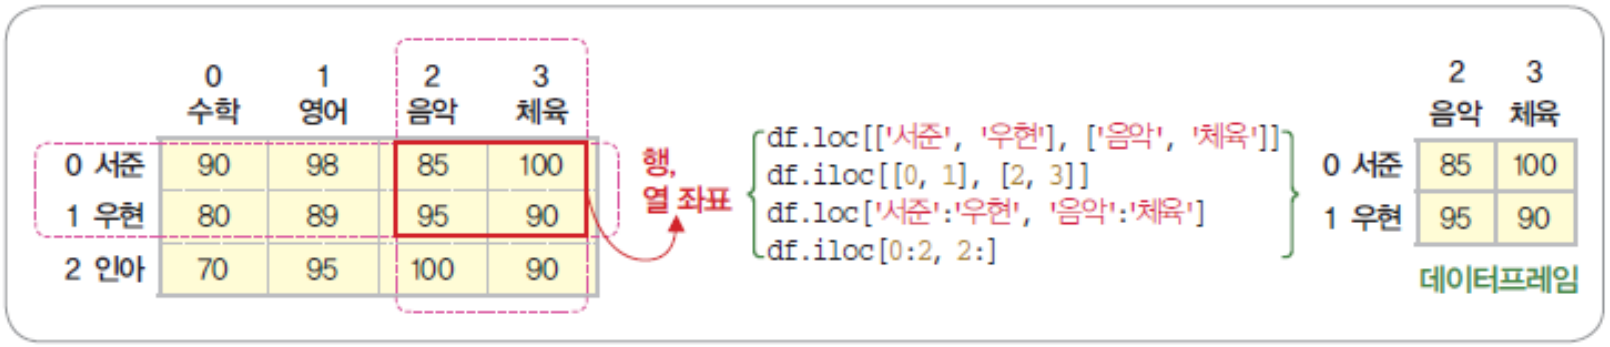

2-2. 데이터프레임

▪ 열 추가

1) 추가하려는 열 이름과 데이터 값을 입력. 마지막 열에 덧붙이듯 새로운 열을 추가.

```
열 추가: DataFrame 객체[ '추가하려는 열 이름' ] = 데이터 값
```

2) 이때 모든 행에 동일한 값이 입력되는 점에 유의.

[그림 1-13] 데이터프레임의 열 추가

[예제 1-12]

다음 예제에서 '국어' 열을 새로 추가하는데, 모든 학생들의 국어 점수가 동일하게 80점으로 입력되는 과정을 보여준다.

```
3  import pandas as pd
4
5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
6  exam_data = {'이름' : [ '서준', '우현', '인아'],
7               '수학' : [ 90, 80, 70],
8               '영어' : [ 98, 89, 95],
9               '음악' : [ 85, 95, 100],
10              '체육' : [ 100, 90, 90]}
11 df = pd.DataFrame(exam_data)
12 print(df)
13 print('\n')
14
15 # 데이터프레임 df에 '국어' 점수 열(column) 추가. 데이터 값은 80 지정
16 df['국어'] = 80
17 print(df)
```

〈실행 결과〉 코드 전부 실행

	이름	수학	영어	음악	체육
0	서준	90	98	85	100
1	우현	80	89	95	90
2	인아	70	95	100	90

	이름	수학	영어	음악	체육	국어
0	서준	90	98	85	100	80
1	우현	80	89	95	90	80
2	인아	70	95	100	90	80

2-2. 데이터프레임

▪ 행 추가

- 추가하려는 행 이름과 데이터 값을 loc 인덱서를 사용하여 입력.
- 하나의 데이터 값을 입력하거나 열의 개수에 맞게 배열 형태로 여러 개의 값(배열의 순서대로 열 위치에 값이 하나씩 추가됨)을 입력할 수 있음
- 행 벡터 자체가 배열이므로, 기존 행을 복사해서 새로운 생에 그대로 추가할 수도 있음

```
행 추가: DataFrame.loc[ '새로운 행 이름' ] = 데이터 값 (또는 배열)
```

- 데이터프레임에 새로운 행을 추가할 때는 기존 행 인덱스와 겹치지 않는 새로운 인덱스를 사용함
- 기존 인덱스와 중복되는 경우 새로운 행을 추가하지 않고 기존 행의 원소값을 변경함
- 행 인덱스를 지정할 때 기존 인덱스의 순서를 따르지 않아도 됨

2-2. 데이터프레임

▪ 행 추가

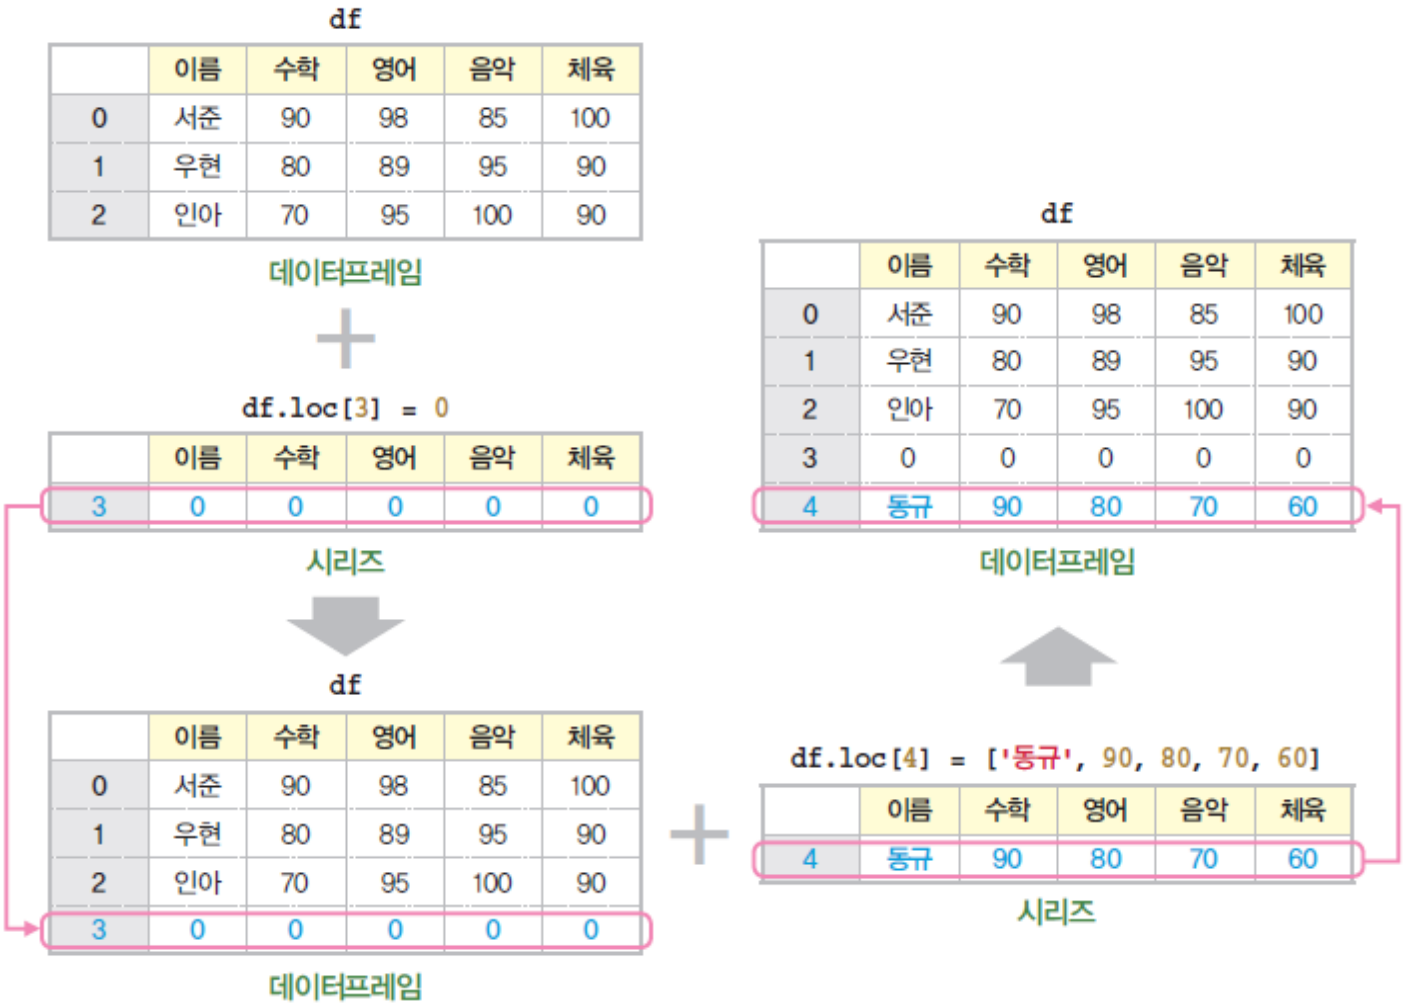

[그림 1-14] 데이터프레임의 행 추가

[예제 1-13]

```
 3  import pandas as pd
 4
 5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
 6  exam_data = {'이름' : ['서준', '우현', '인아'],
 7               '수학' : [ 90, 80, 70],
 8               '영어' : [ 98, 89, 95],
 9               '음악' : [ 85, 95, 100],
10               '체육' : [ 100, 90, 90]}
11  df = pd.DataFrame(exam_data)
12  print(df)
13  print('\n')
14
15  # 새로운 행(row) 추가 - 같은 원소 값 입력
16  df.loc[3] = 0
17  print(df)
18  print('\n')
19
20  # 새로운 행(row) 추가 - 원소 값 여러 개의 배열 입력
21  df.loc[4] = ['동규', 90, 80, 70, 60]
22  print(df)
23  print('\n')
24
25  # 새로운 행(row) 추가 - 기존 행 복사
26  df.loc['행5'] = df.loc[3]
27  print(df)
```

〈실행 결과〉 코드 전부 실행

```
   이름  수학  영어  음악  체육
0  서준  90  98  85  100
1  우현  80  89  95  90
2  인아  70  95  100  90

   이름  수학  영어  음악  체육
0  서준  90  98  85  100
1  우현  80  89  95  90
2  인아  70  95  100  90
3   0   0   0   0   0

   이름  수학  영어  음악  체육
0  서준  90  98  85  100
1  우현  80  89  95  90
2  인아  70  95  100  90
3   0   0   0   0   0
4  동규  90  80  70  60

   이름  수학  영어  음악  체육
0  서준  90  98  85  100
1  우현  80  89  95  90
2  인아  70  95  100  90
3   0   0   0   0   0
4  동규  90  80  70  60
행5  0   0   0   0   0
```

2-2. 데이터프레임

▪ 원소 값 변경

- 특정 원소를 선택하고 새로운 데이터 값을 지정
- 원소 1개를 선택하여 변경할 수도 있고, 여러 개의 원소를 선택하여 한꺼번에 값을 바꿀 수도 있음
- 변경할 원소를 선택할 때 데이터프레임 인덱싱과 슬라이싱 기법을 사용함

원소 값 변경: DataFrame 객체의 일부분 또는 원소를 선택 = 새로운 값

[예제 1-14] ① 1개의 원소를 변경

'서준' 학생의 '체육' 점수를 선택하는 여러 방법을 시도한다. 각 방법을 비교하기 위해, 각기 다른 점수를 새로운 값으로 입력하여 원소를 변경하였다. (변경된 값을 원으로 표시)

```
3  import pandas as pd
4
5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
6  exam_data = {'이름' : [ '서준', '우현', '인아'],
7               '수학' : [ 90, 80, 70],
8               '영어' : [ 98, 89, 95],
9               '음악' : [ 85, 95, 100],
10              '체육' : [ 100, 90, 90]}
11 df = pd.DataFrame(exam_data)
12
13 # '이름' 열을 새로운 인덱스로 지정하고, df 객체에 변경사항 반영
14 df.set_index('이름', inplace=True)
15 print(df)
16 print('\n')
17
18 # 데이터프레임 df의 특정 원소를 변경하는 방법: '서준'의 '체육' 점수
19 df.iloc[0][3] = 80
20 print(df)
21 print('\n')
22
23 df.loc['서준']['체육'] = 90
24 print(df)
25 print('\n')
26
27 df.loc['서준', '체육'] = 100
28 print(df)
```

〈실행 결과〉 코드 1~28라인을 부분 실행

이름	수학	영어	음악	체육
서준	90	98	85	100
우현	80	89	95	90
인아	70	95	100	90

이름	수학	영어	음악	체육
서준	90	98	85	80
우현	80	89	95	90
인아	70	95	100	90

이름	수학	영어	음악	체육
서준	90	98	85	90
우현	80	89	95	90
인아	70	95	100	90

이름	수학	영어	음악	체육
서준	90	98	85	100
우현	80	89	95	90
인아	70	95	100	90

[예제 1-14] ② 1개 이상의 원소를 변경

여러 개의 원소를 선택하여 새로운 값을 할당하면, 모든 원소를 한꺼번에 같은 값으로 변경 가능하다.
선택한 원소의 개수에 맞춰 각기 다른 값을 배열 형태로 입력할 수도 있다.

```
~  ~~~ (생략) ~~~

31  # 데이터프레임 df의 원소 여러 개를 변경하는 방법: '서준'의 '음악', '체육' 점수
32  df.loc['서준', ['음악', '체육']] = 50
33  print(df)
34  print('\n')
35
36  df.loc['서준', ['음악', '체육']] = 100, 50
37  print(df)
```

〈실행 결과〉 코드 31~37라인을 부분 실행

이름	수학	영어	음악	체육
서준	90	98	50	50
우현	80	89	95	90
인아	70	95	100	90

이름	수학	영어	음악	체육
서준	90	98	100	50
우현	80	89	95	90
인아	70	95	100	90

2-2. 데이터프레임

▪ 행, 열의 위치 바꾸기

- 데이터프레임의 행과 열을 서로 맞바꾸는 방법 (선형대수학의 전치행렬과 같은 개념)
- 전치의 결과로 새로운 객체를 반환하므로, 기존 객체를 변경하기 위해서는
  df = df.transpose() 또는 df = df.T 와 같이 새로운 객체를 할당해주는 과정이 필요함

행, 열 바꾸기: `DataFrame 객체.transpose()` **또는** `DataFrame 객체.T`

	이름	수학	영어	음악	체육
0	서준	90	98	85	100
1	우현	80	89	95	90
2	인아	70	95	100	90

	0	1	2
이름	서준	우현	인아
수학	90	80	70
영어	98	89	95
음악	85	95	100
체육	100	90	90

[그림 1-15] 행, 열 바꾸기

[예제 1-15]

```
3  import pandas as pd
4
5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
6  exam_data = {'이름' : [ '서준', '우현', '인아'],
7               '수학' : [ 90, 80, 70],
8               '영어' : [ 98, 89, 95],
9               '음악' : [ 85, 95, 100],
10              '체육' : [ 100, 90, 90]}
11 df = pd.DataFrame(exam_data)
12 print(df)
13 print('\n')
14
15 # 데이터프레임 df를 전치하기(메소드 활용)
16 df = df.transpose()
17 print(df)
18 print('\n')
19
20 # 데이터프레임 df를 다시 전치하기(클래스 속성 활용)
21 df = df.T
22 print(df)
```

〈실행 결과〉 코드 전부 실행

	이름	수학	영어	음악	체육
0	서준	90	98	85	100
1	우현	80	89	95	90
2	인아	70	95	100	90

	0	1	2
이름	서준	우현	인아
수학	90	80	70
영어	98	89	95
음악	85	95	100
체육	100	90	90

	이름	수학	영어	음악	체육
0	서준	90	98	85	100
1	우현	80	89	95	90
2	인아	70	95	100	90

▪ 특정 열을 행 인덱스로 설정

- set_index() 메소드를 사용하여 데이터프레임의 특정 열을 행 인덱스로 설정함
- 원본 데이터프레임을 바꾸지 않고 새로운 객체를 반환하는 점 유의~!

특정 열을 행 인덱스로 설정: DataFrame 객체.set_index(['열 이름'] 또는 '열 이름')

[그림 1-16] 데이터프레임의 특정 열을 행 인덱스로 설정

[예제 1-16]

set_index() 메소드를 사용하여 행 인덱스를 새로 지정하면 기존 행 인덱스는 삭제됨

```
3  import pandas as pd
4
5  # DataFrame() 함수로 데이터프레임 변환. 변수 df에 저장
6  exam_data = {'이름' : [ '서준', '우현', '인아'],
7               '수학' : [ 90, 80, 70],
8               '영어' : [ 98, 89, 95],
9               '음악' : [ 85, 95, 100],
10              '체육' : [ 100, 90, 90]}
11 df = pd.DataFrame(exam_data)
12 print(df)
13 print('\n')
14
15 # 특정 열(column)을 데이터프레임의 행 인덱스(index)로 설정
16 ndf = df.set_index(['이름'])
17 print(ndf)
18 print('\n')
19 ndf2 = ndf.set_index('음악')
20 print(ndf2)
21 print('\n')
22 ndf3 = ndf.set_index(['수학', '음악'])
23 print(ndf3)
```

〈실행 결과〉 코드 전부 실행

```
   이름  수학  영어  음악  체육
0  서준   90   98   85  100
1  우현   80   89   95   90
2  인아   70   95  100   90


     수학  영어  음악  체육
이름
서준   90   98   85  100
우현   80   89   95   90
인아   70   95  100   90


     수학  영어  체육
음악
85     90   98  100
95     80   89   90
100    70   95   90


          영어  체육
수학 음악
90   85    98  100
80   95    89   90
70   100   95   90
```

▪ 행 인덱스 재배열

- reindex() 메소드를 사용하면, 데이터프레임의 행 인덱스를 새로운 배열로 재지정할 수 있음
- 기존 객체를 변경하지 않고, 새로운 데이터프레임 객체를 반환한다.

```
새로운 배열로 행 인덱스를 재지정: DataFrame 객체.reindex( 새로운 인덱스 배열 )
```

- 기존 데이터프레임에 존재하지 않는 행 인덱스가 새롭게 추가되는 경우, 그 행의 데이터 값은 NaN 값이 입력됨.

[예제 1-17]

예제의 14행에서 새롭게 추가된 'r3', 'r4' 인덱스에 해당하는 모든 열에 대해 NaN 값이 입력된다.
이럴 경우, 데이터가 존재하지 않는다는 뜻의 NaN 대신 유효한 값으로 채우려면 예제의 21행과 같이 fill_value 옵션에 원하는 값(0)을 입력한다.
NaN은 “Not a Number” 라는 뜻이다. 유효한 값이 존재하지 않는 누락 데이터를 말한다.

```
3  import pandas as pd
4
5  # 딕셔서리 정의
6  dict_data = {'c0':[1,2,3], 'c1':[4,5,6], 'c2':[7,8,9], 'c3':[10,11,12], 'c4':[13,14,15]}
7
8  # 딕셔너리를 데이터프레임으로 변환. 인덱스를 [r0, r1, r2]로 지정
9  df = pd.DataFrame(dict_data, index=['r0', 'r1', 'r2'])
10 print(df)
11 print('\n')
12
13 # 인덱스를 [r0, r1, r2, r3, r4]로 재지정
14 new_index = ['r0', 'r1', 'r2', 'r3', 'r4']
15 ndf = df.reindex(new_index)
16 print(ndf)
17 print('\n')
18
19 # reindex로 발생한 NaN값을 숫자 0으로 채우기
20 new_index = ['r0', 'r1', 'r2', 'r3', 'r4']
21 ndf2 = df.reindex(new_index, fill_value=0)
22 print(ndf2)
```

〈실행 결과〉 코드 전부 실행

```
    c0  c1  c2  c3  c4
r0   1   4   7  10  13
r1   2   5   8  11  14
r2   3   6   9  12  15


     c0   c1   c2   c3   c4
r0  1.0  4.0  7.0  10.0  13.0
r1  2.0  5.0  8.0  11.0  14.0
r2  3.0  6.0  9.0  12.0  15.0
r3  NaN  NaN  NaN  NaN   NaN
r4  NaN  NaN  NaN  NaN   NaN


    c0  c1  c2  c3  c4
r0   1   4   7  10  13
r1   2   5   8  11  14
r2   3   6   9  12  15
r3   0   0   0   0   0
r4   0   0   0   0   0
```

▪ 행 인덱스 초기화

- reset_index() 메소드를 활용하여 행 인덱스를 정수형 위치 인덱스로 초기화함.
- 기존 행 인덱스는 열로 이동. 새로운 데이터프레임 객체를 반환.

정수형 위치 인덱스로 초기화: DataFrame 객체.reset_index( )

[예제 1-18]

```
3  import pandas as pd
4
5  # 딕셔너리 정의
6  dict_data = {'c0':[1,2,3], 'c1':[4,5,6], 'c2':[7,8,9], 'c3':[10,11,12], 'c4':[13,14,15]}
7
8  # 딕셔너리를 데이터프레임으로 변환. 인덱스를 [r0, r1, r2]로 지정
9  df = pd.DataFrame(dict_data, index=['r0', 'r1', 'r2'])
10 print(df)
11 print('\n')
12
13 # 행 인덱스를 정수형으로 초기화
14 ndf = df.reset_index()
15 print(ndf)
```

〈실행 결과〉 코드 전부 실행

```
    c0  c1  c2  c3  c4
r0   1   4   7  10  13
r1   2   5   8  11  14
r2   3   6   9  12  15


  index  c0  c1  c2  c3  c4
0    r0   1   4   7  10  13
1    r1   2   5   8  11  14
2    r2   3   6   9  12  15
```

▪ 행 인덱스를 기준으로 데이터프레임 정렬

- sort_index() 메소드로 행 인덱스를 기준으로 정렬.

```
행 인덱스 기준 정렬: DataFrame 객체.sort_index( )
```

- ascending 옵션을 사용하여 오름차순 또는 내림차순 설정.
- 새롭게 정렬된 데이터프레임 객체를 반환.

[예제 1-19]

```
3  import pandas as pd
4
5  # 딕셔너리 정의
6  dict_data = {'c0':[1,2,3], 'c1':[4,5,6], 'c2':[7,8,9], 'c3':[10,11,12], 'c4':[13,14,15]}
7
8  # 딕셔너리를 데이터프레임으로 변환. 인덱스를 [r0, r1, r2]로 지정
9  df = pd.DataFrame(dict_data, index=['r0', 'r1', 'r2'])
10 print(df)
11 print('\n')
12
13 # 내림차순으로 행 인덱스 정렬
14 ndf = df.sort_index(ascending=False)
15 print(ndf)
```

〈실행 결과〉 코드 전부 실행

```
    c0  c1  c2  c3  c4
r0   1   4   7  10  13
r1   2   5   8  11  14
r2   3   6   9  12  15


    c0  c1  c2  c3  c4
r2   3   6   9  12  15
r1   2   5   8  11  14
r0   1   4   7  10  13
```

▪ 특정 열의 데이터 값을 기준으로 데이터프레임 정렬

- sort_values() 메소드를 활용하여 새롭게 정렬된 데이터프레임 객체를 반환함.

열 기준 정렬 : DataFrame 객체.sort_values()

예) ndf = df.sort_values(by='c1', ascending=False)

=> 'c1' 열을 기준으로 데이터프레임을 내림차순 정렬함.

▪ 산술연산

- 판다스 객체의 산술연산은 내부적으로 3단계 프로세스를 거친다.

① 행/열 인덱스를 기준으로 모든 원소를 정렬한다.

② 동일한 위치에 있는 원소끼리 일대일로 대응시킨다.

③ 일대일 대응이 되는 원소끼리 연산을 처리한다.
(이때, 대응되는 원소가 없으면 NaN으로 처리한다.)

4-1. 시리즈 연산

▪ 시리즈 vs 숫자

- 시리즈 객체에 어떤 숫자를 더하면 시리즈의 개별 원소에 각각 숫자를 더하고 계산한 결과를 시리즈 객체로 반환함 (사칙연산 모두 가능)

시리즈와 숫자 연산: Series객체 + 연산자(+, -, *, /) + 숫자

[예제 1-21]

```
1  # -*- coding: utf-8 -*-
2
3  # 라이브러리 불러오기
4  import pandas as pd
5
6  # 딕셔너리 데이터로 판다스 시리즈 만들기
7  student1 = pd.Series({'국어':100, '영어':80, '수학':90})
8  print(student1)
9  print('\n')
10
11 # 학생의 과목별 점수를 200으로 나누기
12 percentage = student1/200
13
14 print(percentage)
15 print('\n')
16 print(type(percentage))
```

〈실행 결과〉 코드 전부 실행

```
국어    100
영어     80
수학     90
dtype: int64


국어    0.50
영어    0.40
수학    0.45
dtype: float64


<class 'pandas.core.series.Series'>
```

4-1. 시리즈 연산

▪ 시리즈 vs 시리즈

- 시리즈와 시리즈 사이에 사칙연산 처리.
- 같은 인덱스를 가진 원소끼리 계산.
- 해당 인덱스에 연산 결과를 매칭하여 새 시리즈를 반환.

```
시리즈와 시리즈 연산: Series1 + 연산자(+, -, *, /) + Series2
```

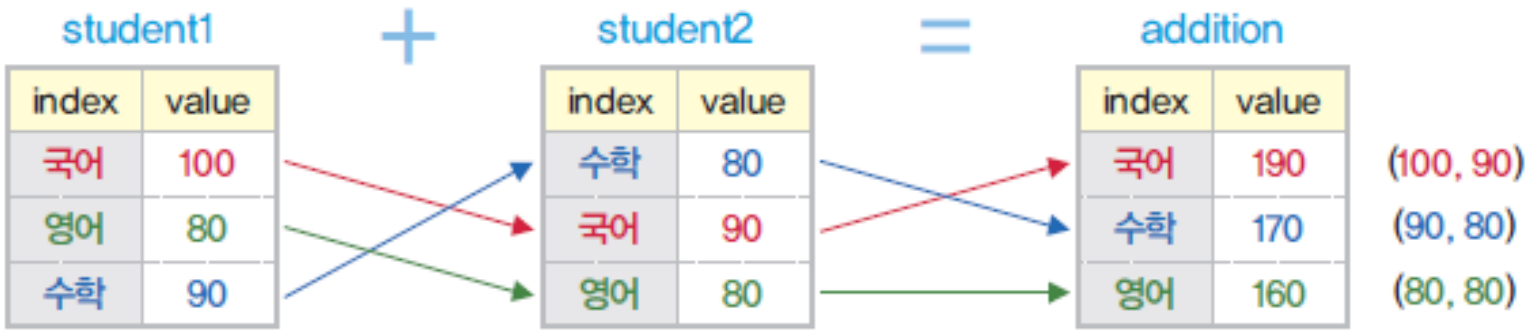

[그림 1-17] 시리즈의 산술연산(덧셈)

[예제 1-22]

```
4  import pandas as pd
5
6  # 딕셔너리 데이터로 판다스 시리즈 만들기
7  student1 = pd.Series({'국어':100, '영어':80, '수학':90})
8  student2 = pd.Series({'수학':80, '국어':90, '영어':80})
9
10 print(student1)
11 print('\n')
12 print(student2)
13 print('\n')
14
15 # 두 학생의 과목별 점수로 사칙연산 수행
16 addition = student1 + student2                # 덧셈
17 subtraction = student1 - student2            # 뺄셈
18 multiplication = student1 * student2         # 곱셈
19 division = student1/student2                 # 나눗셈
20 print(type(division))
21 print('\n')
22
23 # 사칙연산 결과를 데이터프레임으로 합치기(시리즈 -> 데이터프레임)
24 result = pd.DataFrame([addition, subtraction, multiplication, division],
25                        index=['덧셈', '뺄셈', '곱셈', '나눗셈'])
26 print(result)
```

〈실행 결과〉 코드 전부 실행

```
국어    100
영어     80
수학     90
dtype: int64


수학    80
국어    90
영어    80
dtype: int64


<class 'pandas.core.series.Series'>


              국어          수학        영어
덧셈    190.000000    170.000    160.0
뺄셈     10.000000     10.000      0.0
곱셈   9000.000000   7200.000   6400.0
나눗셈     1.111111      1.125      1.0
```

4-1. 시리즈 연산

▪ 시리즈 vs 시리즈

- 두 시리즈의 원소 개수가 다르거나, 혹은 시리즈의 크기가 같더라도 인덱스 값이 다를 수 있음

  -> 유효한 값이 존재하지 않는다는 의미로 NaN으로 처리

- 같은 인덱스가 양쪽에 모두 존재하여 서로 대응되어도 어느 한 쪽의 데이터 값이 NaN인 경우

  -> 연산의 대상인 데이터가 존재하지 않기 때문에, NaN으로 처리

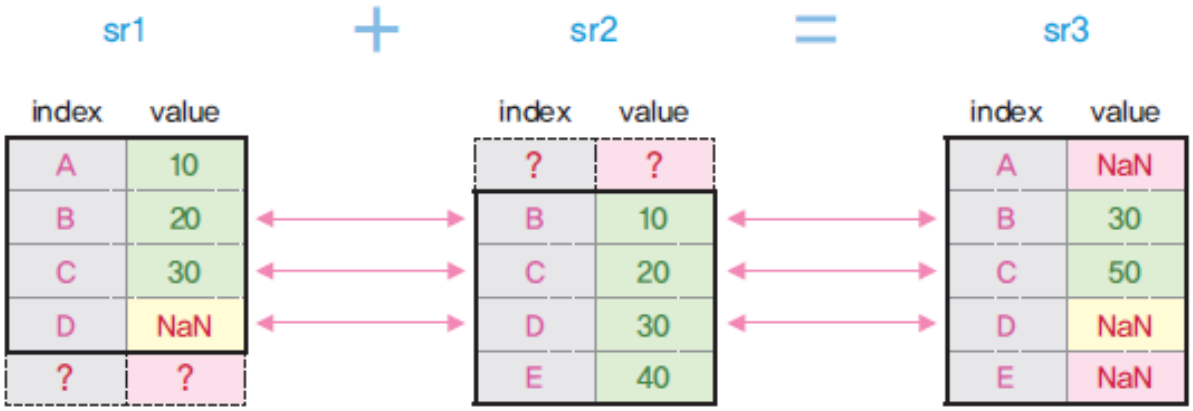

[그림 1-18] NaN값이 있는 시리즈의 산술연산(덧셈)

[예제 1-23]

NaN을 포함한 연산 결과는 NaN로 처리
Numpy는 파이썬 기반 수치 해석 라이브러리로 선형대수 연산에 필요한 다차원 배열과 배열 연산을 수행하는 다양한 함수를 제공

```
3  # 라이브러리 불러오기
4  import pandas as pd
5  import numpy as np
6
7  # 딕셔너리 데이터로 판다스 시리즈 만들기
8  student1 = pd.Series({'국어':np.nan, '영어':80, '수학':90})
9  student2 = pd.Series({'수학':80, '국어':90})
10
11 print(student1)
12 print('\n')
13 print(student2)
14 print('\n')
15
16 # 두 학생의 과목별 점수로 사칙연산 수행(시리즈 vs 시리즈)
17 addition = student1 + student2                  # 덧셈
18 subtraction = student1 - student2              # 뺄셈
19 multiplication = student1 * student2          # 곱셈
20 division = student1/student2                  # 나눗셈
21 print(type(division))
22 print('\n')
23
24 # 사칙연산 결과를 데이터프레임으로 합치기(시리즈 -> 데이터프레임)
25 result = pd.DataFrame([addition, subtraction, multiplication, division],
26                        index=['덧셈', '뺄셈', '곱셈', '나눗셈'])
27 print(result)
```

〈실행 결과〉 코드 전부 실행

```
국어     NaN
영어    80.0
수학    90.0
dtype: float64


수학    80
국어    90
dtype: int64


<class 'pandas.core.series.Series'>


       국어       수학    영어
덧셈   NaN   170.000   NaN
뺄셈   NaN    10.000   NaN
곱셈   NaN  7200.000   NaN
나눗셈 NaN     1.125   NaN
```

4-1. 시리즈 연산

▪ 연산 메소드 활용

- 객체 사이에 공통 인덱스가 없는 경우에 NaN으로 반환.

  -> 이런 상황을 피하려면 연산 메소드에 fill_value 옵션을 설정.

연산 메소드 사용(시리즈와 시리즈 덧셈): `Series1.add(Series2, fill_value=0)`

[예제 1-24]

누락 데이터 NaN 대신 숫자 0을 입력하는 것을 예시로 설명하고 있다.
Result의 '영어' 열의 나눗셈 값은 무한대(inf) 이다.
(student1의 영어 점수 80을 student2의 영어 점수 0으로 나눈 값이기 때문)

```
3  # 라이브러리 불러오기
4  import pandas as pd
5  import numpy as np
6
7  # 딕셔너리 데이터로 판다스 시리즈 만들기
8  student1 = pd.Series({'국어':np.nan, '영어':80, '수학':90})
9  student2 = pd.Series({'수학':80, '국어':90})
10
11 print(student1)
12 print('\n')
13 print(student2)
14 print('\n')
15
16 # 두 학생의 과목별 점수로 사칙연산 수행(연산 메소드 사용)
17 sr_add = student1.add(student2, fill_value=0)     # 덧셈
18 sr_sub = student1.sub(student2, fill_value=0)     # 뺄셈
19 sr_mul = student1.mul(student2, fill_value=0)     # 곱셈
20 sr_div = student1.div(student2, fill_value=0)     # 나눗셈
21
22 # 사칙연산 결과를 데이터프레임으로 합치기(시리즈 -> 데이터프레임)
23 result = pd.DataFrame([sr_add, sr_sub, sr_mul, sr_div],
24                        index=['덧셈', '뺄셈', '곱셈', '나눗셈'])
25 print(result)
```

〈실행 결과〉 코드 전부 실행

```
국어     NaN
영어    80.0
수학    90.0
dtype: float64


수학    80
국어    90
dtype: int64


       국어       수학        영어
덧셈   90.0   170.000  80.000000
뺄셈  -90.0    10.000  80.000000
곱셈    0.0  7200.000   0.000000
나눗셈  0.0     1.125        inf
```

4-2. 데이터프레임 연산

- 데이터프레임은 여러 시리즈가 한데 모인 것이므로, 시리즈 연산을 확장하는 개념으로 이해
- 먼저 행/열 인덱스를 기준으로 정렬하고, 일대일 대응되는 원소끼리 연산함

▪ 데이터프레임 vs 숫자

- 데이터프레임에 어떤 숫자를 더하면, 모든 원소에 숫자를 더함.
  (덧셈, 뺄셈, 곱셈, 나눗셈 모두 가능)
- 기존 데이터프레임의 형태를 그대로 유지한 채, 원소 값만 새로운 값으로 바꿈.

```
데이터프레임과 숫자 연산: DataFrame 객체 + 연산자(+, -, *, /) + 숫자
```

[예제 1-25]

[타이타닉('titanic') 데이터셋]
Seaborn 라이브러리에서 제공하는 데이터셋으로, 타이타닉호 탑승자에 대한 인적사항과 구조 여부 등을 정리한 자료. load_dataset() 함수로 불러옴

[Seaborn 내장 데이터셋의 종류]
'anscombe', 'attention', 'brain_networks', 'car_crashes', 'diamonds', 'dots', 'exercise', 'flights', 'fmri', 'gammas', 'iris', 'mpg', 'planets', 'tips', 'titanic'

```
3  # 라이브러리 불러오기
4  import pandas as pd
5  import seaborn as sns
6
7  # titanic 데이터셋에서 age, fare 2개 열을 선택하여 데이터프레임 만들기
8  titanic = sns.load_dataset('titanic')
9  df = titanic.loc[:, ['age','fare']]
10 print(df.head())          # 첫 5행만 표시
11 print('\n')
12 print(type(df))
13 print('\n')
14
15 # 데이터프레임에 숫자 10 더하기
16 addition = df + 10
17 print(addition.head())    # 첫 5행만 표시
18 print('\n')
19 print(type(addition))
```

〈실행 결과〉 코드 전부 실행

```
    age     fare
0  22.0   7.2500
1  38.0  71.2833
2  26.0   7.9250
3  35.0  53.1000
4  35.0   8.0500


<class 'pandas.core.frame.DataFrame'>


    age     fare
0  32.0  17.2500
1  48.0  81.2833
2  36.0  17.9250
3  45.0  63.1000
4  45.0  18.0500

class 'pandas.core.frame.DataFrame'>
```

4-2. 데이터프레임 연산

▪ 데이터프레임 vs 데이터프레임

- 각 데이터프레임의 같은 행, 같은 열 위치에 있는 원소끼리 계산함
- 이처럼 동일한 위치의 원소끼리 계산한 결과값을 원래 위치에 다시 입력하여 데이터프레임을 만듬
- 데이터프레임 중 어느 한쪽에 원소가 존재하지 않거나 NaN이면 연산 결과는 NaN으로 처리

데이터프레임의 연산자 활용: `DataFrame1 + 연산자(+, -, *, /) + DataFrame2`

df1

	열 A	열 B	열 C
행 0	15	100	1
행 1	20	500	2
행 2	50	200	3
행 3	NaN	500	2
행 4	NaN	200	3

+

df2

	열 A	열 B
행 0	10	200
행 1	10	100
행 2	10	200
행 3	20	100
행 4	30	100

=

df1+df2

	열 A	열 B	열 C
행 0	25	300	NaN
행 1	30	600	NaN
행 2	60	400	NaN
행 3	NaN	600	NaN
행 4	NaN	300	NaN

[그림 1-19] 데이터프레임의 산술연산(덧셈)

[예제 1-26]

```
3  # 라이브러리 불러오기
4  import pandas as pd
5  import seaborn as sns
6
7  # titanic 데이터셋에서 age, fare 2개 열을 선택하여 데이터프레임 만들기
8  titanic = sns.load_dataset('titanic')
9  df = titanic.loc[:, ['age','fare']]
10 print(df.tail())          # 마지막 5행 표시
11 print('\n')
12 print(type(df))
```

```
15 # 데이터프레임에 숫자 10 더하기
16 addition = df + 10
17 print(addition.tail())          # 마지막 5행 표시
18 print('\n')
19 print(type(addition))
20 print('\n')
21
22 # 데이터프레임끼리 연산하기(additon - df)
23 subtraction = addition - df
24 print(subtraction.tail())       # 마지막 5행 표시
25 print('\n')
26 print(type(subtraction))
```

〈실행 결과〉 코드 전부 실행

```
      age   fare
886  27.0  13.00
887  19.0  30.00
888   NaN  23.45
889  26.0  30.00
890  32.0   7.75

<class 'pandas.core.frame.DataFrame'>

      age   fare
886  37.0  23.00
887  29.0  40.00
888   NaN  33.45
889  36.0  40.00
890  42.0  17.75

<class 'pandas.core.frame.DataFrame'>

      age  fare
886  10.0  10.0
887  10.0  10.0
888   NaN  10.0
889  10.0  10.0
890  10.0  10.0

<class 'pandas.core.frame.DataFrame'>
```

감사합니다

「전공별 AI활용」